CH8 課後綜合練習

一、選擇題 (共 25 題)

1. BeautifulSoup 的主要功能是什麼？ (A) 解析 HTML/XML 網頁原始碼並提取資料 (B) 自動填寫網路表單與發送 POST 請求 (C) 進行資料庫的備份與資料還原 (D) 執行 JavaScript 程式碼以動態渲染網頁
2. 在 CSS Selector 中，代表選擇特定「id」屬性的符號是什麼？ (A) . (點號) (B) # (井字號) (C) * (星號) (D) @ (老鼠號)
3. 在 CSS Selector 中，代表選擇特定「class」屬性的符號是什麼？ (A) # (井字號) (B) > (大於符號) (C) . (點號) (D) 空格
4. 若 CSS Selector 寫成 div p（中間有空格），其選取邏輯為何？ (A) 選取與 div 相同層級的 p 標籤 (B) 選取 div 的直接子代（下一層）p 標籤 (C) 選取所有同時包含 div 和 p 的標籤 (D) 選取 div 內部的所有子孫後代 p 標籤
5. 若 CSS Selector 寫成 ul > li（中間是大於符號），其選取邏輯為何？ (A) 選取 ul 的「直接子代」li 標籤 (B) 選取 ul 內部的所有子孫 li 標籤 (C) 選取緊接在 ul 後面的第一個 li 標籤 (D) 選取所有大於特定數量的 li 標籤
6. 使用 BeautifulSoup 進行選取時，select() 方法會回傳什麼型態的結果？ (A) 單一個標籤物件 (Tag Object) (B) 包含所有符合條件標籤的列表 (List) (C) 一個包含純文字的字串 (D) None 或是布林值
7. 使用 select_one() 方法時，如果網頁中找不到符合條件的標籤，會回傳什麼？ (A) 拋出 IndexError 異常 (B) 回傳一個空的列表 [] (C) 回傳 None (D) 拋出 AttributeError 異常
8. 關於 .text 與 .string 的主要差異，下列何者正確？ (A) .text 是方法需要加括號，.string 是屬性 (B) .string 會自動忽略所有的 HTML 實體編碼 (C) 兩者在任何結構下的回傳結果完全相同 (D) 當標籤內含有巢狀子標籤時，.string 會回傳 None，而 .text 能成功提取所有文字
9. 若要在 BeautifulSoup 中安全地提取標籤的屬性（例如圖片的 src），建議使用哪種方式以防止屬性不存在時程式崩潰？ (A) tag.get('src') (B) tag['src'] (C) tag.text('src') (D) tag.select_one('src')
10. 當使用 BeautifulSoup 提取 class 屬性時（例如 tag.get('class')），其預設回傳的資料型態為何？ (A) 字串 (String) (B) 列表 (List) (C) 字典 (Dictionary) (D) 元組 (Tuple)
11. 對於可能缺失某些欄位的電商商品清單，在爬取時應如何編寫程式以確保穩定性？ (A) 使用 try...except 直接忽略整個網頁 (B) 一律使用字典語法強制取值 (C) 配合 if 條件判斷或三元運算子給予預設值 (D) 只爬取完全對稱的網頁
12. 在 for 迴圈遍歷多個商品容器時，若在迴圈內部誤用了 soup.select_one(".price") 而非 item.select_one(".price")，會導致什麼後果？ (A) 程式會直接噴出錯誤並中斷 (B) 什麼

資料都抓不到，一律回傳 None (C) 每一筆商品都會抓到自己正確的價格 (D) 每一圈都只會抓到「整頁第一個商品」的價格，失去個別處理的意義（全局選取陷阱）

13. 解析完一組包含多個商品（有名稱、價格、折扣）的嵌套清單後，最常轉化成 Python 的哪種結構來儲存？ (A) 列表套字典 (List of Dictionaries) (B) 字典套元組 (Dictionary of Tuples) (C) 集合套列表 (Set of Lists) (D) 單一長字串
14. 從網頁中抓取到的價格字串（如 "1500"），若之後要拿來進行大小比較或數學計算，必須先使用什麼函式處理？ (A) str( ) (B) int( ) 或 float( ) (C) len( ) (D) strip( )
15. 想要快速且簡潔地將一個分類容器下的所有 <li> 標籤文字提取出來並組成一個新列表，最適合使用 Python 的哪項特性？ (A) 匿名函式 lambda (B) 裝飾器 Decorator (C) 列表生成式 List Comprehension (D) 生成器表達式 Expression
16. 為了去除網頁文字兩端不可見的空格或換行符號，應該使用 Python 內建的哪一個字串方法？ (A) replace( ) (B) split( ) (C) clean( ) (D) strip( )
17. 當我們想要一次性處理某區塊內的多個子標籤文字，並自定義它們之間的分隔符號（例如用直線「|」隔開），應該使用什麼方法？ (A) tag.get_text(separator="|") (B) tag.text.split("|") (C) tag.string("|") (D) tag.select("|")
18. 若在執行爬蟲程式時看到 AttributeError: 'NoneType' object has no attribute 'text'，這代表什麼意思？ (A) 你的 BeautifulSoup 套件沒有正確匯入 (B) 前方的定位選取器沒有抓到標籤（回傳了 None），卻對它調用了 .text (C) 網頁完全沒有任何文字內容 (D) 提取出來的文字類型不屬於字串
19. 若想在一個複雜的區塊中切開所有字串、去除空白，並自動過濾掉純空格的行，可以使用 BeautifulSoup 的哪一個生成器（Generator）？ (A) .text (B) .get_text( ) (C) .stripped_strings (D) .strings
20. 爬取超連結時，如果抓到了相對路徑（如 /news/page1），應該結合哪一個模組來將其轉換為完整的絕對路徑？ (A) os.path.join (B) requests.utils (C) json.dumps (D) urllib.parse.urljoin
21. 關於 CSS Selector 的長路徑連寫（如 .shop .box .item .title），下列敘述何者正確？ (A) 雖然非常精準，但網頁結構一旦微調或改版就極易失效 (B) 可以大幅提升爬蟲程式的執行速度 (C) 是 BeautifulSoup 官方最推薦的唯一寫法 (D) 可以自動將相對路徑轉換為絕對路徑
22. 如果不採用「容器化選取」，而是單獨抓取全網頁的標題列表與價格列表，再用 zip( ) 縫合，最大的風險是什麼？ (A) 記憶體會瞬間過載崩潰 (B) 萬一網頁中間漏掉某個標籤，後續的資料就會全部錯位 (C) 縫合後的資料會自動變成 None (D) 提取出來的資料會自動沾黏在一起
23. 當網頁中包含 HTML 實體編碼（如   或 &）時，BeautifulSoup 會如何處理？ (A) 直接報錯並停止解析 (B) 將其視為註解並直接刪除 (C) 自動將其轉回對應的正常符號（如空格或 &） (D) 完整保留   字串不作任何變更

24. 下列哪一種 CSS Selector 寫法代表同時篩選出「具有 link 類別且 id 為 target」的 a 標籤？ (A) a .link #target (B) a > link > target (C) a, link, target (D) a.link#target
25. 在防禦性爬蟲程式設計中，使用 tag.get('href', '#') 語法時，第二個參數 '#' 的作用是什麼？ (A) 指定只抓取含有井字號的網址 (B) 當 'href' 屬性不存在時，自動以此預設值取代以防出錯 (C) 將該標籤設定為最優先爬取對象 (D) 強制將回傳結果轉換為 List 型態

二、填充題 (共 15 題)

1. 在 BeautifulSoup 中，select_one() 方法若找到多個符合條件的元素，只會回傳 _____符合的標籤物件。
2. CSS Selector 中，選取直接下一層子代使用 > 符號，而選取所有層級的子孫後代則使用 _____（空白鍵）。
3. 若要判斷一個標籤內是否只有純文字、且無任何子標籤嵌套，應使用_____屬性。
4. 為了避免網頁局部結構缺失導致程式當掉，在提取屬性時，應優先使用_____方法而非字典語法。
5. 當我們使用 BeautifulSoup 提取網頁的 class 屬性時，回傳的 Python 資料型態會是 _____。
6. 為了解決多個子標籤文字提取時發生「文字黏在一起」的問題，可以呼叫 get_text() 並指定 _____ 參數。
7. 「先大後小、局部查找」以確保資料對應正確的爬蟲選取策略，在觀念中被稱為_____選取策略。
8. 在 for 迴圈中，若錯誤地在內部繼續對整個全域物件進行選取，此現象稱為掉入 _____選取陷阱。
9. Python 的_____（或稱 Inline If）是處理缺失標籤時，用來賦予預設值最優雅的一行寫法。
10. 爬取到的網頁文字前後常有不可見的換行或空白，可搭配 Python 字串的 _____ 方法進行清理。
11. 如果不想使用容器化，可以使用 Python 內建的 _____ 函數來對應縫合兩個獨立的清單，但錯位風險較高。
12. AttributeError: 'NoneType' object has no attribute 'text' 錯誤通常是因為前方的定位器什麼都沒抓到，其值為 _____。
13. 網頁中的   在被 BeautifulSoup 提取文字時，會被自動轉換為_____。
14. 寫出能夠精準定位但缺點是網頁改版即失效的長路徑選取方式（如 .a .b .c），稱為 CSS Selector 的_____。
15. [li.text for li in items] 這種能讓代碼更簡潔且執行效率高的 Python 特性叫做 _____。

三、實作題 (共 3 題)

實作題 1：網路新聞清單全面解析（結合相對網址與缺失值處理）

題目說明： 請撰寫一段 Python 程式碼，使用 BeautifulSoup 解析一段新聞列表的 HTML 字串。

1. 使用「容器化選取策略」遍歷每一個新聞卡片（.news-card）。
2. 提取新聞標題。
3. 提取超連結（href 屬性）。由於網頁使用的是相對路徑（例如 /news/101），請將其與基礎網址 https://news.example.com 進行串接，組合成完整的絕對路徑。
4. 提取發布時間（.date）。注意：有些緊急推播的新聞可能沒有標記日期，若找不到日期標籤，請預設顯示 "即時新聞"。
5. 將所有新聞整理成「列表套字典（List of Dictionaries）」的結構並印出。

提示：

- 先使用 soup.select(".news-card") 找出所有新聞容器。
- 在迴圈內部使用 item.select_one(".title a") 找出連結標籤，並用 .get("href") 取得相對路徑，再用字串相加或 f-string 與基礎網址結合。
- 使用三元運算子（Inline If）判斷日期標籤是否存在，若為 None 則賦予 "即時新聞"。

輸入範例一

```
html_data = """
<div class="news-list">
    <div class="news-card">
        <h2 class="title"><a href="/news/2026-051">今日天氣晴朗紫外線偏高</a></h2>
        <span class="date">2026-05-21</span>
    </div>
    <div class="news-card">
        <h2 class="title"><a href="/news/2026-052">【突發】國道發生追撞事故
</a></h2>
        </div>
</div>
"""
```

輸出結果一

```
[{'title': '今日天氣晴朗紫外線偏高', 'link': 'https://news.example.com/news/2026-051', 'date':
'2026-05-21'}, {'title': '【突發】國道發生追撞事故', 'link':
'https://news.example.com/news/2026-052', 'date': '即時新聞'}]
```

實作題 2：電影評分與標籤清洗（結合型態轉換與列表生成式）

題目說明： 某電影評論網站的 HTML 結構如下，請撰寫程式解析並將資料結構化。

1. 找出所有的電影區塊（.movie-item）。
2. 提取電影名稱並使用 .strip() 去除兩端多餘的空格與換行。
3. 提取電影評分（.rating），並將文字（如 "評分：8.7"）中的數字部分過濾出來，轉換為 **浮點數（float）** 型態。
4. 每個電影區塊內都有多個標籤（.tags span），請使用列表生成式（List Comprehensions）將該電影的所有標籤文字提取出來，組成一個獨立的 List。
5. 將最終結果整理儲存於一個 Python 字典（Dictionary）中，以電影名稱作為 Key，其 Value 則包含評分與標籤。

提示：

- 評文字串可以使用 .replace("評分：", "") 移除中文字，再用 float() 進行型態轉換。
- 提取標籤時，可以在電影容器內使用 [span.text for span in item.select(".tags span")] 快速建立標籤清單。

輸入範例一

```
html_data = """
<div class="movie-container">
    <div class="movie-item">
        <h3 class="name">    全面啟動 (Inception)    </h3>
        <p class="rating">評分：8.8</p>
        <div class="tags">
            <span>科幻</span><span>懸疑</span><span>動作</span>
        </div>
    </div>
    <div class="movie-item">
        <h3 class="name">    玩具總動員 (Toy Story)    </h3>
        <p class="rating">評分：8.3</p>
        <div class="tags">
            <span>動畫</span><span>冒險</span><span>喜劇</span>
        </div>
    </div>
</div>
"""
```

輸出結果一

```
{'全面啟動 (Inception)': {'rating': 8.8, 'tags': ['科幻', '懸疑', '動作']}, '玩具總動員 (Toy Story)': {'rating': 8.3, 'tags': ['動畫', '冒險', '喜劇']}}
```

實作題 3：相簿圖片牆防禦性提取（結合屬性防錯與特殊網址）

題目說明： 在爬取相簿或圖片牆時，有些圖片可能因為加載失敗或屬於廣告，漏掉了 src 屬性，或者根本沒有圖片標籤。請撰寫防禦性爬蟲程式：

1. 遍歷相簿內的所有相片格子（.gallery-box）。
2. 提取相片標題（.photo-title）。
3. 提取圖片的 src 屬性。
4. **防錯機制**：如果該圖片標籤（<img>）不存在，或者該標籤內沒有寫 src 屬性，請一律讓圖片網址預設為 "https://example.com/images/default.jpg"。
5. 依序將每張相片的解析結果格式化輸出。

提示：

- 先定位 img_tag = item.select_one("img")。
- 判斷 img_tag 是否為 None。如果不是 None，再使用 .get("src", "預設網址") 安全提取屬性。如果 img_tag 本身就是 None，則直接給予預設網址。

輸入範例一

```
html_data = """
<div class="gallery">
    <div class="gallery-box">
        <span class="photo-title">墾丁美麗海灘</span>
        <img class="preview" src="https://example.com/img/kenting.jpg">
    </div>
    <div class="gallery-box">
        <span class="photo-title">阿里山日出</span>
        <img class="preview"> </div>
    <div class="gallery-box">
        <span class="photo-title">贊助商廣告</span>
        </div>
</div>
"""
```

輸出結果一

```
相片：墾丁美麗海灘 -> 網址：https://example.com/img/kenting.jpg
相片：阿里山日出 -> 網址：https://example.com/images/default.jpg
相片：贊助商廣告 -> 網址：https://example.com/images/default.jpg
```